§7 МЕТОД СПУСКА

Пусть $f: X \to \mathbb{R}$ — дифференцируемая выпуклая функция, а значит, для всех $x, y \in X$ выполнено неравенство $f(y) \ge f(x) + \nabla f(x)^{\mathsf{T}} (y-x)$. Для численного определения минимального значения функции f используют так называемый метод

Алгоритм 7.1. Общий метод спуска

Input: начальное приближение $x \in X$ **Output:** приближённое решение

- ${f 1}$ while не выполнен критерий останова ${f do}$
- определить направление спуска Δx
- 3 выбрать размер шага t 4 $x \leftarrow x + t\Delta x$
- 5 return x

спуска, который заключается в построении последовательностей векторов $(x^k)_{k\in\mathbb{N}_0}, \ (\Delta x^k)_{k\in\mathbb{N}_0}$ и действительных чисел $(t_k)_{k\in\mathbb{N}_0},$ таких что $x^{k+1}=x^k+t^k\Delta x^k\in X$ и $f(x^{k+1})\leq f(x^k),$ где $x^0\in X$ — заданный начальный вектор.

На практике, элементы последовательности $(x^k)_{k\in\mathbb{N}_0}$ вычисляются до тех пор пока не будет выполнен критерий остано-

ва. Например, для заданного $\varepsilon>0$, таким условием является выполнение одно из неравенств: $\|x^{k+1}-x^k\|\leq \varepsilon, \ |f(x^{k+1})-f(x^k)|<\varepsilon, \ \|\nabla f(x^k)\|\leq \varepsilon.$

Так как f — выпуклая функция, то из неравенства $\nabla f(x^k)^\mathsf{T}(y-x^k) > 0$ следует, что $f(y) > f(x^k)$. Таким образом, в методе спуска необходимо выполнение неравенства $\nabla f(x^k)^\mathsf{T} \Delta x^k \leq 0$. Будем говорить, что вектор Δx является направлением спуска в точке x, если $\nabla f(x)^\mathsf{T} \Delta x \leq 0$. Последовательность $(t^k)_{k \in \mathbb{N}_0}$ называется последовательностью размеров шагов. Метод спуска имеет множество вариаций, которые различаются способом вычисления направлений спуска $(\Delta x^k)_{k \in \mathbb{N}_0}$ и размеров шагов $(t_k)_{k \in \mathbb{N}_0}$.

Далее будем предполагать, что $X=\mathbb{R}^n$. Пусть Δx — направление спуска в точке x. Рассмотрим два способа определения размера шага t. Первый способ заключается в решении следующей задачи

$$t^* = \arg\min_{t \ge 0} f(x + t\Delta x)$$

и называется методом наискорейшего спуска (Exact Line Search, ELS). Второй

Алгоритм 7.2. Backtracking Line Search

Input: направление спуска Δx , $\alpha \in (0, 1/2)$, $\beta \in (0, 1)$

 ${f Output:}$ размер шага t

- $1 \ t \leftarrow 1$
- 2 while $f(x + t\Delta x) > f(x) + \alpha t \nabla f(x)^{\mathsf{T}} \Delta x$ do
- $\mathbf{s} \mid t \leftarrow \beta t$
- $_{4}$ return $_{t}$

способ называется Backtracking Line Search (BLS) и зависит от двух параметров $\alpha \in \left(0, \frac{1}{2}\right), \, \beta \in (0, 1)$. Начиная с t = 1, будем уменьшать t, умножением на β , до тех пор пока не будет выполнено неравенство $f(x + t\Delta x) \leq f(x) + \alpha t \nabla f(x)^\mathsf{T} \Delta x$. Нетрудно показать, что если выполнено неравенство $\nabla f(x)^\mathsf{T} \Delta x < 0$, то искомое t будет найдено за конечное число итераций. Действительно,

$$f(x + t\Delta x) = f(x) + t\nabla f(x)^{\mathsf{T}} \Delta x + o(t) = f(x) + \alpha t \nabla f(x)^{\mathsf{T}} \Delta x + th(t),$$

где $h(t) = \left(\frac{o(t)}{t} + (1-\alpha)\nabla f(x)^\mathsf{T} \Delta x\right)$. При достаточно малом t>0 функция h(t) принимает отрицательные значения.

Зафиксируем точку x и определим направление ℓ^* , $\|\ell^*\|=1$, наибольшего убывания, т.е. $\ell^*=\arg\min_{\ell\in\mathbb{S}^{n-1}}\frac{\partial f(x)}{\partial \ell}$, где $\mathbb{S}^{n-1}\stackrel{\mathrm{def}}{=}\{x\colon\|x\|=1\}$ — сфера единичного радиуса с центром в начале координат. Так как $\frac{\partial f(x)}{\partial \ell}=\nabla f(x)^\mathsf{T}\ell\geq -\|\nabla f(x)\|$, то направление наибольшего убывания ℓ^* сонаправлено с $-\nabla f(x)$. Метод спуска, в котором $\Delta x=-\nabla f(x)$, называется методом градиентного спуска. Перед тем, как провести анализ сходимости метода градиентного спуска, докажем ряд

Пусть $A, B \in \mathbb{R}^{n \times n}$ — квадратные матрицы порядка n с вещественными элементами. Если матрица C = A - B является неотрицательно определённой, т.е. для любого $x \in \mathbb{R}^n$ выполнено неравенство $x^\mathsf{T} C x \geq 0$, то будем писать $A \succeq B$. Для векторов будем использовать евклидову норму, а для матриц — спектральную.

вспомогательных утверждений [1].

Лемма 7.1. Пусть $f \in C^2(\mathbb{R}^n)$ и нашлось такое положительное число m, что $\nabla^2 f(x) \succeq mI$, $x \in \mathbb{R}^n$. Тогда для всех x, y справедливы неравенства

$$f(y) \ge f(x) + \nabla f(x)^{\mathsf{T}} (y - x) + \frac{m}{2} ||y - x||^2;$$
 (7.1)

$$\min_{y \in \mathbb{R}^n} f(y) \ge f(x) - \frac{1}{2m} \|\nabla f(x)\|^2; \tag{7.2}$$

$$||x - x^*|| \le \frac{2}{m} ||\nabla f(x)||, \quad \epsilon \partial e \quad x^* = \arg\min_{x \in \mathbb{R}^n} f(x).$$
 (7.3)

ightharpoonup Согласно формуле Тейлора существует такая точка z, принадлежащая отрезку [x,y], что $f(y)=f(x)+\nabla f(x)^\mathsf{T}(y-x)+rac{1}{2}(y-x)^\mathsf{T}\nabla^2 f(z)(y-x).$

Так как $abla^2 f(z) - mI$ — неотрицательно определённая матрица, то

$$(y-x)^{\mathsf{T}} (\nabla^2 f(z) - mI)(y-x) \ge 0,$$

т.е. $(y-x)^{\mathsf{T}} \nabla^2 f(z) (y-x) \ge m \|y-x\|^2$, а значит, имеет место неравенство (7.1).

§7 Метод спуска 36

При фиксированном x функция $g(y)=f(x)+\nabla f(x)^{\mathsf{T}}(y-x)+\frac{m}{2}\|y-x\|^2$ является строго выпуклой. Нетрудно видеть, что $\widetilde{y}=x-\frac{1}{m}\nabla f(x)$ — стационарная точка функции g, а значит, в этой точке функция g принимает минимальное значение. Другими словами, $g(y)\geq g(\widetilde{y})=f(x)-\frac{1}{2m}\|\nabla^2 f(x)\|,\ y\in X.$ То, что $\min_{x\in\mathbb{R}^n}f(x)$ существует и достигается в единственной точке $x^*\in\mathbb{R}^n$ следует из неравенства (7.1) и строгой выпуклости функции f. Так как $f(y)\geq g(y)$, то выполнено неравенство (7.2).

В силу (7.2) имеем

$$0 \ge f(x^*) - f(x) \ge \nabla f(x)^{\mathsf{T}} (x^* - x) + \frac{m}{2} ||x^* - x||^2 \ge$$
$$\ge -||\nabla f(x)|| ||x^* - x|| + \frac{m}{2} ||x^* - x||^2.$$

Из последнего, в частности, следует неравенство (7.3). ⊲

Лемма 7.2. Пусть $f \in C^2(\mathbb{R}^n)$ и нашлось такое положительное число M, что $\nabla^2 f(x) \leq MI$. Тогда для всех $x, y \in \mathbb{R}^n$ справедливы неравенства:

$$f(y) \le f(x) + \nabla f(x)^{\mathsf{T}} (y - x) + \frac{M}{2} \|y - x\|^{2},$$

$$\inf_{y \in X} f(y) \le f(x) - \frac{1}{2M} \|\nabla f(x)\|^{2}.$$
(7.4)

⊳ Доказательство аналогично доказательству леммы 7.1.

Наконец, перейдём к анализу сходимости метода градиентного спуска.

Теорема 7.1. Пусть $f \in C^2(\mathbb{R}^n)$ и существуют такие положительные числа $m,\ M>0,\$ что $mI \preceq \nabla^2 f(x) \preceq MI,\ x\in \mathbb{R}^n.$ Обозначим $x^*=\arg\min_{x\in \mathbb{R}^n} f(x),\$ а через $(x^k)_{k\in \mathbb{N}_0}$ — последовательность, построенную методом градиентного спуска. Тогда $f(x^k)-f(x^*)\leq c^k\big(f(x^0)-f(x^*)\big),\$ где $c=1-m/M,\$ если последовательность $(t^k)_{k\in \mathbb{N}_0}$ строится согласно процедуре ELS, и $c=1-2\alpha m\min(1,\beta/M),\$ если последовательность $(t^k)_{k\in \mathbb{N}_0}$ строится согласно процедуре BLS.

ightharpoonup Зафиксируем точку x и пусть $g(t)=f\left(x-t\nabla f(x)\right)$. Из неравенства (7.4) следует, что $g(t)\leq f(x)+\left(\dfrac{Mt^2}{2}-t\right)\|\nabla f(x)\|^2$. Пусть t_E — размер шага, полученный согласно ELS. Тогда

$$g(t_E) \le g\left(\frac{1}{M}\right) \le f(x) - \frac{1}{2M} \|\nabla f(x)\|^2$$

(мы сравниваем со значением функции g в точке M^{-1} , так как функция $Mt^2/2-t$ принимает там минимальное значение). Из (7.2) следует, что

$$\|\nabla f(x)\|^2 \ge 2m(f(x) - f(x^*)).$$

Таким образом, $f(x - t_E \nabla f(x)) - f(x^*) \le (1 - m/M)(f(x) - f(x^*)).$

Пусть t_B — размер шага, который полученный согласно процедуре BLS. Покажем, что $t_B=1$ или $t_B\geq \beta/M$. Действительно, при $0\leq t\leq M^{-1}$ справедлива цепочка неравенств

$$g(t) \le f(x) - t \|\nabla f(x)\|^2 + \frac{Mt^2}{2} \|\nabla f(x)\|^2 \le f(x) - \frac{t}{2} \|\nabla f(x)\|^2 \le f(x) - \alpha t \|\nabla f(x)\|^2.$$

Если $t_B=1$, то $f\big(x-t_B\nabla f(x)\big)\leq f(x)-\alpha\|\nabla f(x)\|^2$, а если $t_B\geq \beta/M$, то верно $f\big(x-t_B\nabla f(x)\big)\leq f(x)-\frac{\alpha\beta}{M}\|\nabla f(x)\|^2$. Таким образом,

$$f(x - t_B \nabla f(x)) - f(x^*) \le f(x) - f(x^*) - \alpha \min\left(1, \frac{\beta}{M}\right) \|\nabla f(x)\|^2.$$

А значит, в силу неравенства (7.2) имеем

$$f(x - t_B \nabla f(x)) \le (1 - 2\alpha m \min(1, \beta/M)) (f(x) - f(x^*)).$$

Предположение о том, что $\nabla^2 f(x) \succeq mI$, $x \in \mathbb{R}^n$, является достаточно сильным. Оказывается, что сходимость имеет место и без этого предположения. Мы не будем приводить формулировку и доказательство этого результата, так как он будет следовать из анализа, проведённого в §?? при обсуждении метода проекций градиента.

В зависимости от максимального порядка смешанных производных целевой функции f, которые участвуют в методе оптимизации, различают прямые методы поиска (или метод нулевого порядка), методы первого порядка, методы второго порядка и т.д. В прямых методах поиска используется информация только о самой функции и не используется информация о её производных. Как правило, такие методы применяются, когда аналитическое представление функции f не известно. Методы первого порядка при поиске решения используют информацию как о самой функции, так и о её производных первого порядка. Рассмотренный метод градиентного спуска является методом первого порядка. Далее будет рассмотрен метод Ньютона, который является методом второго порядка, так как в этом методе используются информация о самой функции и о её производных первого и второго порядков.

Пусть $f \in C^2(\mathbb{R}^n)$ — выпуклая функция, гессиан $\nabla^2 f(x)$ которой обратим в каждой точке $x \in \mathbb{R}^n$. Из последнего, в частности, следует, что $\nabla^2 f(x)$ — положительно определённая матрица для любого $x \in \mathbb{R}^n$. Выпишем формулу Тейлора второго порядка для функции f в окрестности некоторой фиксированной точки x:

$$f(x+v) = f(x) + \nabla f(x)^{\mathsf{T}} v + \frac{1}{2} v^{\mathsf{T}} \nabla^2 f(x) v + o(\|v\|^2).$$

Функция $h(v) = f(x) + \nabla f(x)^\mathsf{T} v + \frac{1}{2} v^\mathsf{T} \nabla^2 f(x) v$ принимает минимальное значение в точке $v^* = -\nabla^2 f(x)^{-1} \nabla f(x)$. Направление $\Delta x = v^*$ называется шагом Ньютона.

§7 Метод спуска 38

Минимальное значение функции h равно

$$h(\Delta x) = f(x) - \frac{1}{2} \nabla f(x)^{\mathsf{T}} \nabla^2 f(x)^{-1} \nabla f(x) = f(x) - \frac{1}{2} \lambda(x)^2 \approx f(x + \Delta x),$$

где $\lambda(x) \stackrel{\text{def}}{=} (\nabla f(x)^{\mathsf{T}} \nabla^2 f(x)^{-1} \nabla f(x))^{\frac{1}{2}}$. Непосредственно проверяется, что

$$\lambda(x)^{2} = -\nabla f(x)^{\mathsf{T}} \Delta x = \Delta x^{\mathsf{T}} \nabla^{2} f(x) \Delta x.$$

Метод спуска, в котором направление спуска равно шагу Ньютона, называется

Алгоритм 7.3. Метод Ньютона

Input: начальное приближение $x \in \mathbb{R}^n$, $\varepsilon > 0$

Output: приближённое решение

- 1 repeat
- $\mathbf{z} \mid \Delta x \leftarrow -\nabla^2 f(x)^{-1} \nabla f(x)$
- $\lambda(x)^2 \leftarrow \nabla f(x)^\mathsf{T} \nabla^2 f(x)^{-1} \nabla f(x)$
- 4 Определить размер шага t согласно BLS
- $x \leftarrow x + t\Delta x$
- 6 until $\lambda(x)^2/2 > \varepsilon$
- 7 return x

методом Ньютона. Для определённости будем считать, что размер шага $t=t_B$ в этом методе выбирается согласно BLS.

Для анализа метода Ньютона докажем вспомогательные леммы.

Лемма 7.3. Если для выпуклой функции $f \in C^2(\mathbb{R}^n)$ существуют такие числа $m,\ M>0,\$ что $mI \preceq \nabla^2 f(x) \preceq MI,\$ то $f(x+t_B\Delta x)-f(x) \leq -\frac{\alpha\beta m}{M^2}\|\nabla f(x)\|^2.$ \rhd Согласно условию леммы справедливы неравенства

$$\lambda(x)^2 = \Delta x^\mathsf{T} \nabla^2 f(x) \Delta x \ge m \|\Delta x\|^2,$$

$$\lambda(x)^2 = \nabla f(x)^\mathsf{T} \nabla^2 f(x)^{-1} \nabla f(x) \ge \frac{\|\nabla f(x)\|^2}{M}.$$

Из неравенства (7.4) следует, что $f(x+t\Delta x) \leq f(x) - t\lambda(x)^2 + \frac{M}{2m}t^2\lambda(x)^2$. Полагая в последнем неравенстве t=m/M, получаем, что

$$f(x + t\Delta x) \le f(x) - \frac{m}{2M}\lambda(x)^2 \le f(x) - \alpha t\lambda(x)^2.$$

Следовательно, $t_B \ge \beta m/M$. Таким образом,

$$f(x + t_B \Delta x) - f(x) \le -\alpha t_B \lambda(x)^2 \le -\alpha \beta \frac{m}{M} \lambda(x)^2 \le -\frac{\alpha \beta m}{M^2} \|\nabla f(x)\|^2. \quad \triangleleft$$

Лемма 7.4. Пусть для функции $f \in C^2(\mathbb{R}^n)$ и чисел m, M, L > 0 верно, что

$$mI \preceq \nabla^2 f(x) \preceq MI \quad u \quad \|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x-y\|, \quad x,y \in \mathbb{R}^n.$$

Тогда $\|\nabla f(x + \Delta x)\| \le \frac{L}{2m^2} \|\nabla f(x)\|^2$ и если $\|\nabla f(x)\| \le 3(1 - 2\alpha) \frac{m^2}{L}$, то $t_B = 1$. \triangleright Докажем первую часть утверждения леммы.

$$\|\nabla f(x + \Delta x)\| = \|\nabla f(x + \Delta x) - \nabla f(x) - \nabla^2 f(x) \Delta x\| =$$

$$= \|\int_0^1 (\nabla^2 f(x + t\Delta x) - \nabla^2 f(x)) \Delta x \, dt\| \le \frac{L}{2} \|\Delta x\|^2 =$$

$$= \frac{L}{2} \|\nabla^2 f(x)^{-1} \nabla f(x)\|^2 \le \frac{L}{2m^2} \|\nabla f(x)\|^2.$$

Пусть $g(t) \stackrel{\text{def}}{=} f(x + t\Delta x)$, тогда получаем $g''(t) = \Delta x^{\mathsf{T}} \nabla^2 f(x + t\Delta x) \Delta x$. В силу условия леммы справедливы неравенства:

$$|g''(t) - g''(0)| = |\Delta x^{\mathsf{T}} (\nabla^2 f(x + t\Delta x) - \nabla^2 f(x)) \Delta x| \le tL ||\Delta x||^3$$

и $g''(0)=\lambda(x)^2\geq m\|\Delta x\|^2$. Тогда $g''(t)\leq g''(0)+tL\|\Delta x\|^3\leq \lambda(x)^2+\frac{tL}{m^{3/2}}\lambda(x)^3$. Проинтегрировав дважды последнюю цепочку неравенств, учитывая равенство $g'(0)=-\lambda(x)^2$, и положив t=1, получаем $f(x+\Delta x)\leq f(x)-\frac{1}{2}\lambda(x)^2+\frac{L}{6m^{3/2}}\lambda(x)^3$. Так как $\|\nabla f(x)\|\leq 3(1-2\alpha)\frac{m^2}{L}$, то $\lambda(x)\leq 3(1-2\alpha)\frac{m^{3/2}}{L}$. Следовательно,

$$f(x+\Delta x) \leq f(x) - \lambda(x)^2 \left(\frac{1}{2} - \frac{L\lambda(x)}{6m^{3/2}}\right) \leq f(x) - \alpha\lambda(x)^2 = f(x) + \alpha\nabla f(x)^\mathsf{T}\Delta x.$$

Таким образом, $t_B = 1$. \triangleleft

Теорема 7.2. Пусть для функции $f \in C^2(\mathbb{R}^n)$ и чисел m, M, L > 0 верно, что $mI \preceq \nabla^2 f(x) \preceq MI$ и $\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x-y\|$, $x,y \in \mathbb{R}^n$. Обозначим $x^* = \arg\min_{x \in \mathbb{R}^n} f(x)$, а через $(x^k)_{k \in \mathbb{N}_0}$ — последовательность, построенную методом Ньютона. Тогда для любого $\varepsilon > 0$ верно неравенство $f(x^k) - f(x^*) < \varepsilon$ при

$$k \geq N_\varepsilon \stackrel{\text{def}}{=} \frac{f(x^0) - f(x^*)}{\gamma} + \log_2 \log_2 \left(\frac{m^3}{L^2\varepsilon}\right), \quad \textit{ide} \quad \gamma = \gamma(m, M, L).$$

ho Пусть $\eta \stackrel{\mathrm{def}}{=} \min (1, 3(1-2\alpha)) \frac{m^2}{L}$. Если $\|\nabla f(x)\| \leq \eta$, то из леммы 7.4, в частности, следует, что $\|\nabla f(x+\Delta x)\| \leq \frac{\eta}{2}$. Действительно, так как $\frac{L}{m^2} \leq \eta^{-1}$, то

§7 Метод спуска 40

 $\|\nabla f(x+\Delta x)\| \leq \frac{L}{2m^2} \|\nabla f(x)\|^2 \leq \frac{\eta}{2}.$ Через s обозначим наименьшее натуральное число, такое что $\|\nabla f(x^s)\| \leq \eta.$ Из леммы 7.3 следует, что $s \leq \frac{f(x^0) - f(x^*)}{\gamma}$, где $\gamma \stackrel{\text{def}}{=} \alpha \beta \eta^2 \frac{m}{M^2}.$ Тогда при k > s справедливо неравенство $\|\nabla f(x^k)\| < \eta$, а значит,

$$\frac{L}{2m^2}\|\nabla f(x^k)\| \leq \left(\frac{L}{2m^2}\|\nabla f(x^{k-1})\|\right)^2 \leq \left(\frac{L}{2m^2}\|\nabla f(x^s)\|\right)^{2^{k-s}} \leq \left(\frac{1}{2}\right)^{2^{k-s}}.$$

Из неравенства (7.2) следует, что $f(x^k) - f(x^*) \le \frac{1}{2m} \|\nabla f(x^k)\| \le \frac{m^3}{L^2} 2^{-2^{k-s}} < \varepsilon$. \lhd

Упражнения

- 19. (Метод сопряжённых направлений) Пусть A положительно определённая матрица и $f(x) = \frac{1}{2} x^\mathsf{T} A x b^\mathsf{T} x + c$. Векторы (направления) p и q назовём A-сопряжёнными, если $p^\mathsf{T} A q = 0$. Для данного начального приближения x^0 и последовательности ненулевых сопряжённых направлений $(p^k)_{k=0}^{n-1}$ определим последовательность точек $(x^k)_{k=1}^n$ равенством $x^{k+1} = x^k + t^k p^k$, где $t^k = \arg\min_{t \in \mathbb{R}} f(x^k + tp^k)$. Докажите, что
 - (a) $t^k = -(p^k, \nabla f(x^k))/(p^k, Ap^k);$
 - (b) вектор $\nabla f(x^{k+1})$ ортогонален направлениям p^0, p^1, \ldots, p^k ;
 - (c) $\nabla f(x^n) = 0$, а значит, x^n минимум функции f(x);
 - (d) последовательность направлений $(p^k)_{k=0}^{n-1}$ может быть определена как

$$\begin{cases} p^0 = -\nabla f(x^0), \\ p^k = -\nabla f(x^k) + \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^{k-1})\|^2} p^{k-1}, & 1 \le k < n. \end{cases}$$

Указание: Пусть $L_k \stackrel{\text{def}}{=} \operatorname{Span}(p^0, Ap^0, \dots, A^k p^0)$. Индукцией по k докажите, что p^k и $\nabla f(x^k) \in L^k$, при этом Ap^k и $\nabla f(x^k) \in L^k_{k-1}$.

Литература

Boyd S., Vandenberghe L. Convex Optimization – Cambridge University Press, 2004.
 730 c.